

为美国市场提供中国开源模型服务 API 的商业调研报告

执行摘要

本调研聚焦“在美国市场以 API 形式提供中国开源/开放权重模型（以 Minmax/Kimi/GLM 为代表）”的商业可行性与进入路径，重点覆盖美国个人用户与小型开发团队付费意愿、现有供给与竞争格局、直接调用中国境内部署服务的限制，以及在美国商业化模式、定价与合规风险缓解。结论上：“只卖中国境内 API”在美国可规模化程度有限；更可行的路径是“以开放权重为核心，在美国本土云/本地化部署 + 合规与数据驻留承诺 + OpenAI 兼容接口 + 成本/性能路由”，把“模型来源”与“数据与合规边界”解耦，从而覆盖更广的美国付费客户群体。¹

从“付费意愿”的可观测证据看，美国开发者对多模型与低成本推理的接受度正在提升：OpenRouter 与 a16z 的真实流量研究显示，在其平台样本中，中国开放权重模型在 2025 年从极低基数增长到某些周接近总 token 使用量的约 30%，全年平均约 13%，并伴随新模型发布出现持续性而非短期试用式的使用提升，指向真实工作负载迁移。² 同时，开发者整体层面 AI 工具使用已非常普遍（Stack Overflow 开发者调查显示 2025 年 84% 的受访者在使用或计划使用 AI 工具），这意味着“为开发工作流付费”已经具备基础土壤；但“为第二个通用聊天助手再付一份订阅费”的意愿较弱（a16z 援引 Yipit 的消费者数据：仅约 9% 消费者为多个主流助手同时付费）。³

竞争格局上，美国企业级基础模型支出仍由美国三强主导：Menlo Ventures 在其 2025 企业生成式 AI 报告中估算，企业 LLM 支出份额约为 Anthropic 40%、OpenAI 27%、Google 21%（2025 年）。⁴ 因此，中国模型在美国企业端要突破，关键不在“模型是否更便宜”，而在合规（特别是涉及美国敏感数据跨境）、数据驻留（美国本土/特定州/行业要求）、采购可审计性（DPA、日志、保留期、渗透测试与安全认证）与可用性 SLA。美国司法部数据安全计划（Data Security Program）自 2025-04-08 生效，并将与“国家关注国家（含中国）”相关的特定数据交易纳入限制/禁止框架，显著提高了“把美国敏感数据直接发往中国/受其管辖实体”的合规门槛。⁵

建议的市场进入优先级为：先切入成本敏感、合规压力相对可控的“开发者/小团队生产力场景”（编码、内容生成、轻量客服、内部知识库但不处理“批量敏感个人数据”），并提供“可选的美国本土部署与零/短保留”以逐步进入更高合规行业；中长期再以“在美国本土托管开放权重 + 可审计合规包 + 多模型路由（含美国三强与中国开源）”，成为“合规版多模型 API 层”。⁶

研究范围、方法与关键假设

本报告讨论的“中国开源模型”采用更贴近市场现实的口径：包含“开源代码/开放权重（open-weight）可自部署、可商业使用”的模型家族（例如 Kimi 与部分 MiniMax、GLM 家族的开源/开放权重版本），以及围绕它们提供的官方 API 与第三方托管推理（美国本土云上运行的托管服务）。OpenRouter 的研究也使用“开放权重（open-weight）”并把模型按“中国 vs 其他地区”来源做标注，这为衡量真实使用趋势提供了可引用的数据基础。⁷

方法上，本报告优先使用：

其一，供应商官方文档（定价、隐私、数据驻留、支付方式）；其二，行业研究（OpenRouter+a16z 的 100T token 实证研究、Menlo 企业支出份额研究、a16z 消费者使用与付费集中度分析）；其三，美国监管文件与官方说明（司法部数据安全计划、联邦公报中的最终规则与行政令文本、BIS 关于开放权重模型权重出口的一般立场）。⁸

关键假设与不确定点（将直接影响“美国付费意愿”与“可服务客户范围”）如下：

- **市场份额口径不确定**：多数中国模型厂商不披露美国地区 API 调用量/营收/活跃客户数。本报告对“市场占有率”的量化主要使用 OpenRouter 平台样本（真实 token 路由数据）与 Menlo 的企业支出份额作为两条互补参照：前者更贴近“开发者多模型/开放权重使用”，后者更贴近“美国企业付费结构”。两者都不是“全市场精确统计”。⁹
- **美国合规可用范围假设**：假设目标业务将服务美国客户并可能处理一定量的企业数据，则会受到美国司法部数据安全计划对“国家关注国家/受其控制主体”相关数据交易的约束与尽调压力；具体是否触发“受限/禁止交易”取决于数据类型、规模阈值、交易结构与主体关系，必须在落地时做律师意见与数据映射。¹⁰
- **“中国模型”与“数据驻留”可分离假设**：假设业务可以通过开放权重在美国本土云（例如美国区域）部署，从而避免把客户内容/日志跨境发送到中国境内或受其管辖实体；这一点决定了能否进入更高合规行业与更大客单。开放权重在美国出口管制语境下通常较“闭源权重”风险更低，BIS 在 AI 扩散框架的说明中也强调目前不对开放权重模型权重施加出口许可要求（同时持续监测风险）。¹¹
- **模型许可与商用权不确定**：虽然 Kimi K2.5、部分 MiniMax、GLM 4.5 等在其模型卡/仓库中声明采用 MIT/Modified MIT 等许可并允许商用，但不同模型版本、不同组件（权重、代码、数据、第三方 notices）可能存在差异；商业化前需逐条核对许可证文本与“二次分发/托管推理/商标使用/归因要求”。¹²

美国个人用户与小型开发团队的付费意愿

美国个人开发者与小团队对大模型付费的“意愿”通常不是抽象态度，而是由三类可观测行为决定：是否把模型接入工作流（频次/留存）、是否为“可替代能力”支付溢价、以及是否愿意为合规与稳定性付费。Stack Overflow 2025 调查显示开发者对 AI 工具的采用已非常广泛（84% 使用或计划使用，专业开发者中日用比例更高），说明“为提升开发效率付费”的心理门槛显著下降。¹³

但在消费级“通用助手订阅”形态上，付费高度集中：a16z 消费者 AI 报告援引 Yipit 数据指出，只有约 9% 消费者为多个主流助手同时付费，反映出多数个人用户**不愿为第二个相似助手重复付费**；这意味着若产品定位是“另一个聊天助手”，来自美国个人用户的付费空间会被头部品牌强烈挤压。¹⁴

对“开发者/API 付费”更直接的证据来自 OpenRouter 的 100T token 实证研究：其数据显示开放权重模型整体在 2025 年逐步增长到约三分之一的使用量，而中国开放权重模型从 2024 年末最低约 1.2% 的周份额增长到 2025 年部分周接近 30%，全年平均约 13%。这种增长与关键模型发布节点相关且具有持续性，被研究解释为更接近生产使用而非短期试用。⁷ 在同一研究中，开放权重模型的高流量场景主要集中于“角色扮演/创作”和“编程”，而编程类需求在整体 token 占比中快速上升，表明**付费意愿更强的群体往往是把模型当作生产工具的人群（编码、内容生产、代理式工作流）**。¹⁵

将上述证据映射到“是否愿意为中国模型付费”，可以得出更细分的判断：

- **个人/独立开发者（Indie）**：更看重“价格/性能比 + 易用（OpenAI 兼容）+ 快速试用的支付门槛”。Kimi 平台支持绑定 Visa/Mastercard/UnionPay 并且最低 1 美元充值，降低试用门槛；DeepSeek 也在其文档中列出 PayPal、银行卡、支付宝、微信等充值方式，说明其产品形态本就面向全球开发者的“小额充值一按量计费”。¹⁶
- **小型开发团队/初创（2-30 人）**：愿意为“可控成本（缓存、批量、路由）+ 可预测账单 + 基本 SLA/工单响应”付费，且更愿意接受“多模型组合”而不是单一供应商。OpenRouter 研究中提到新模型可在数周内获得生产规模采用，暗示开发者侧切换成本在下降；这类团队对“便宜且好用”的模型更敏感。¹⁷
- **对中国来源敏感的美国企业用户**：即便模型性能与价格具吸引力，仍可能因为数据驻留与合规尽调而拒绝直接对接中国境内/受中国管辖的 API（下文详述 DOJ 数据安全计划与数据驻留问题）；因此其付费

意愿更多指向“在美国本土部署的开放权重版本”或“由美国/中立司法辖区实体提供的托管推理”。

18

美国市场供给格局与竞争对比

本节按“能否在美国用户侧实际使用/购买”来列出现有供给：包括中国模型厂商的官方 API（通常跨境交付）、提供海外（新加坡）端点的国际化平台，以及在美国本土提供端点与数据驻留的云服务形态。总体上，数据驻留位置（美国/新加坡/中国）是区分“可服务客户上限”的关键变量。

19

主要供应商与服务形态对比

下表以“供应商—服务形式—定价—客户类型—合规/数据驻留公开说明”为主轴（币种统一为 USD、价格按官方页面的“每 1M tokens 输入/输出”口径；若供应商支持缓存则单列）。

20

供应商	服务形式（API/托管/自托管镜像）	公开定价策略（代表性模型）	典型客户类型（推断自产品形态）	合规与数据驻留公开说明（关键点）
稀宇科技（MiniMax）	官方 API；按量付费与订阅档位；开放权重可自托管（Hugging Face）	MiniMax-M2.5：输入 \$0.30 / 输出 \$1.20（高性能档更高） ²¹ ；亦有月订阅 Token Plan（\$10/\$20/\$50 等） ²²	偏开发者与多模态内容生成用户（文本/音频/视频/图像同平台） ²¹	Open Platform 隐私政策在搜索摘要中表述“可能在一个或多个司法辖区的服务器处理与存储数据”，未给出单一美国本土驻留承诺 ²³
月之暗面 ²⁴ （Kimi）	官方 API（OpenAI 兼容迁移指南亦在其文档中体现）；开放权重模型可自托管（Hugging Face）	官方站点展示 kimi-k2.5：缓存命中 \$0.10 / 输入 \$0.60 / 输出 \$3.00（每 1M tokens） ²⁵	面向国际开发者的按量计费 API（低门槛充值、开发者文档完善） ²⁶	明确声明服务器位于新加坡 ²⁷ ，个人数据可能在新加坡处理与存储 ²⁸

供应商	服务形式（API/托管/自托管镜像）	公开定价策略（代表性模型）	典型客户类型（推断自产品形态）	合规与数据驻留公开说明（关键点）
智谱AI ²⁹ (GLM/Z.ai)	国际站 API (docs.z.ai)；中国站 open.bigmodel.cn；开放权重模型可自托管 (Hugging Face/GitHub)	GLM-4.7：输入 \$0.60 / 输出 \$2.20；GLM-4.7-FlashX：输入 \$0.07 / 输出 \$0.40（每 1M tokens） ³⁰ ；另有订阅制 Coding Plan 页面 ³¹	开发者/编码工具订阅用户与 API 开发团队	隐私政策披露服务通常从新加坡提供、个人数据一般在新加坡处理，并提供 API 服务的数据处理附录（DPA）结构 ³²
DeepSeek ³³	官方 API；开放权重可自托管	deepseek-chat：输入（cache miss）\$0.27 / 输出 \$1.10；deepseek-reasoner：输入（cache miss）\$0.55 / 输出 \$2.19（每 1M tokens） ³⁴	全球开发者按量计费；提供自助退款等计费功能 ³⁵	隐私政策明确：信息存储在中华人民共和国的服务器（对美国合规与采购影响显著） ³⁶
阿里云 ³⁷ (Qwen 生态)	Model Studio 托管推理 API；可选“美国模式/全球模式/国际模式/中国大陆模式”；Qwen 开放权重可自托管	官方文档说明：US 部署模式端点与数据存储在美国（弗吉尼亚州），推理资源限制在美国 ³⁸ ；International 模式端点与数据存储在新加坡 ³⁹	更偏企业/开发者（云平台控制台、区域选择、配额与套餐）	明确提供美国数据驻留（US 模式：端点与数据存储在美国弗吉尼亚州 ⁴⁰ ） ³⁸ ；Qwen 代码许可为 Apache 2.0（利于商用与再分发） ⁴¹
OpenAI ⁴²	官方 API；多企业版产品与隐私合规承诺	GPT-5.4：输入 \$2.50 / 输出 \$15.00（每 1M tokens） ⁴³	企业与开发者；生态与工具链最成熟	企业隐私页面声明默认不使用业务数据训练，并披露 SOC 2 Type II 等合规信息；API 默认日志保留最长 30 天，并可申请更严格的数据保留控制（含 Zero Data Retention） ⁴⁴
Anthropic ⁴⁵	官方 API	以 Opus 4.6 为例：输入 \$5 / 输出 \$25（每 1M tokens） ⁴⁶ ；并披露超长提示（>200k tokens）存在更高档费率 ⁴⁷	企业与开发者，尤其编码/代理式工作流	其产品发布公告披露定价结构与长上下文策略 ⁴⁸

供应商	服务形式（API/托管/自托管镜像）	公开定价策略（代表性模型）	典型客户类型（推断自产品形态）	合规与数据驻留公开说明（关键点）
Google ⁴⁹ (Gemini Developer API)	官方 API；亦可通过云平台获得更强的企业合规选项	Gemini Developer API 定价页列出多模型阶梯价；以 2.5 Pro 为例： 输入 \$1.25（≤200k）/ 输出 \$10（≤200k）（每 1M tokens），并披露“是否用于改进产品”等项 ⁵⁰	企业与开发者	Vertex AI 文档强调未经许可不使用数据训练，并提供“零数据保留”能力体系 ⁵¹

在美市场占有率的估算与与美国三强的相对对比

由于多数中国模型厂商未公开“美国地区 API 调用量/营收/客户数”，本报告提供两种可操作的“相对比较”口径，并明确其局限：

口径一（开发者/多模型平台样本）：OpenRouter 的实证研究显示，**中国开放权重模型在其平台总 token 使用量中的周份额从 1.2% 的低点上升到部分周接近 30%，全年平均约 13%**；另外，美国是其最大的计费地区，约占全球 token 的 47.17%。这意味着在“多模型 API 层”的样本中，**中国开源/开放权重模型已经进入可观的开发者使用份额区间**，并且美国开发者是该样本的重要组成部分。 ⁵²

口径二（美国企业付费口径）：Menlo Ventures 对 2025 年企业 LLM 支出的估算中，企业端主要由 Anthropic（40%）、OpenAI（27%）、Google（21%）占据，合计约 88%；剩余约 12% 分布于其他供应商与开源方案。该结果表明：在美国**企业预算**层面，中国模型即使在开发者社区获得关注，也往往尚未转化为可观的“企业付费份额”。 ⁴

为了更直观看到“开放权重生态内部”的中美对比，OpenRouter 在“关键开放权重参与者”部分给出了开放权重作者的累计 token 量（Nov 2024–Nov 2025）。其中中国作者（DeepSeek、Qwen、MiniMax、Z-AI、MoonshotAI）合计占其列示的头部开放权重作者 token 量的大部分（这是“开放权重内部结构”，不代表全市场结构）。 ⁵³

下面用 Mermaid 饼图展示该“开放权重作者 token 量（Top 列表）”中“中国作者 vs 其他作者”的相对比例（基于 OpenRouter 文中列示作者 token 量求和后再汇总）。 ⁵⁴

```
pie title OpenRouter: 开放权重作者Token量Top列表 (Nov 2024–Nov 2025) 中国作者 vs 其他作者
"中国作者 (DeepSeek/Qwen/MiniMax/Z-AI/MoonshotAI)" : 23.32
"其他作者 (Meta/Mistral/OpenAI/TNGTech/Google)" : 10.48
```

与美国三强的“规模”对比方面，公开口径更多集中在用户数与营收：例如 TechCrunch 报道 OpenAI 披露 ChatGPT 达到约 9 亿周活跃用户（2026-02），Google 的 Gemini 应用达到约 7.5 亿月活（2026-02 的财报口径），而 Reuters 报道 OpenAI 年化收入在 2025 年已超过 200 亿美元。 ⁵⁵ 这些数字与中国模型厂商（尤其开源权重为主的形态）可获取的公开披露不在一个透明度层级上，因此本报告将“与三强的差距”更多落在**合规与采购可达市场（TAM 可触达部分）**而非“模型能力单点”。 ⁵⁶

美国用户直接使用中国境内部署模型服务的限制与风险

本节讨论“美国用户直接调用中国境内（或明确在中国存储数据）的模型 API”时，最常见的阻碍因素。核心结论是：对个人/小团队来说，阻碍多来自支付与网络体验；对能够产生规模收入的企业客户来说，阻碍更多来自法律合规、数据主权与采购政策。⁵⁷

付款渠道与结算摩擦

跨境 API 的商业化往往先卡在“能否顺利收款”。从公开文档看，不同中国厂商的国际化程度差异很大：Kimi 文档明确支持绑定 Visa/Mastercard/UnionPay 并允许最低 1 美元充值；DeepSeek 文档列出 PayPal、银行卡以及支付宝/微信等方式。¹⁶ 这类“低门槛充值 + 按量计费”对美国个人开发者更友好；但若某些平台主要以人民币结算、要求本地实名或对公开票流程，都会显著抬高美国小团队的采购成本（不仅是价格，更是财务流程时间）。⁵⁸

网络连通性与延迟

跨境往返时延本身会降低“交互式场景”（编码助手、IDE inline 建议、Agent 多轮工具调用）的体验上限；更重要的是，中国网络治理与跨境链路波动会带来更高的不确定性。学术与测量研究长期表明“中国防火长城（GFW）”会以多种机制影响跨境连接（包括连接重置、过滤与对新协议的审查），并在近年扩展到对 QUIC 的特定域名/机制封锁。⁵⁹ 对美国企业客户而言，即使模型本身成本更低，一旦网络波动导致重试、超时与并发受限，综合成本与 SLA 风险会迅速放大。⁶⁰

法律合规与监管环境

美国在 2024–2025 年对“把美国敏感数据提供给国家关注国家/受其管辖主体”的监管显著收紧。美国司法部数据安全计划明确其目标是禁止或限制国家关注国家（含中国）及其“受控/受指挥主体”通过某些交易获得美国政府相关数据或美国人的大规模敏感个人数据，并在 DOJ 网站中将其描述为“类似出口管制”的框架，自 2025-04-08 起生效。¹⁰ 行政令文本也明确指出国家关注国家对美国敏感个人数据的获取会带来国家安全风险，并提到 AI 可用于对这些数据进行分析利用。⁶¹

对“提供中国境内部署 API 给美国客户”的实际影响在于：一旦客户数据触及规则关注的类别（例如健康、金融、地理位置等）并达到“bulk”阈值或涉及政府相关数据，客户与供应商都可能需要面对“交易是否被禁止/受限、是否需要许可、是否需满足特定安全要求与尽调留痕”的问题。¹⁰ 这类不确定性会直接进入美国企业的供应商风险评估清单，从而降低采购通过率。⁵⁶

隐私与数据主权

不同供应商在“数据存在哪里”这一点上公开承诺差异显著：Kimi 明确其服务器位于新加坡；Z.ai 的隐私政策也称其服务通常从新加坡提供、个人数据一般在新加坡处理；而 DeepSeek 的隐私政策明确写明信息存储在中国境内服务器。⁶² 对美国企业客户来说，哪怕业务场景本身不触及 DOJ 规则的“bulk 敏感数据阈值”，“数据明确落地中国境内”往往依然会触发更严格的内部政策审查与更高的供应商替代倾向。⁶³

此外，如果业务涉及在中国境内处理个人信息，仍需考虑中国数据合规体系对数据处理与跨境流动的约束（例如 PIPL 的域外适用条款与数据处理义务框架；以及中国网络安全法对关键信息基础设施运营者数据本地化的要求）。⁶⁴ 虽然这些主要约束的是在中国境内运营的主体，但它们会影响供应商的数据治理与与客户签署的合同条款，进而影响美国采购方对“可控性/可追责性”的判断。⁶⁴

企业采购政策与 SLA

美国企业采购对 AI API 的“最低可接受集”通常包含：安全与隐私条款（DPA/数据保留/加密/访问控制）、可审计性（日志、访问记录、渗透测试、第三方报告）、以及业务连续性（状态页、SLA、支持响应）。美国三强在公开材料中更强调可审计与数据控制：例如 OpenAI 的企业隐私页面强调默认不训练业务数据、SOC 2 Type II 等合规信息；其开发者文档也披露 API 默认日志保留最长 30 天并可申请更严格的数据保留控制。⁴⁴ Google 在 Vertex AI 文档中强调未经许可不得使用数据训练，并提供零数据保留体系；其 Gemini Developer API 定价页也把“是否用于改进产品”作为披露项之一。⁶⁵ 相比之下，若中国供应商仅提供“跨境 API + 非美国本土驻留 + 无明确可审计合规包”的组合，往往难以进入高客单企业场景。⁶⁶

在美商业化模式、定价建议、合规与风险缓解措施、市场进入步骤

本节给出“可落地”的商业模式与进入步骤，目标是最大化美国可服务市场，同时把地缘政治与数据合规风险控制可在管理范围内。核心策略是：**以开放权重为核心资产，把“推理托管与数据驻留”放在美国本土（或客户指定区域）完成，把“模型来源”变成技术选项而不是合规负担。**⁶⁷

可行商业模式组合

模式一：美国本土托管的“开放权重推理云”（核心推荐）

提供：OpenAI 兼容接口 + 多模型选择（Minimax/Kimi/GLM 开放权重 + 其他主流开源）+ 缓存/批量/路由 + 专有安全与合规包。该模式的商业价值在于：一方面吸收中国开放权重模型在成本与可部署性上的优势（OpenRouter 数据显示其在开放权重生态中增长显著）；另一方面把数据驻留与合规控制权握在美国部署层，降低 DOJ 数据安全计划与企业采购阻力。⁶⁷

模式二：多模型 API 聚合与“成本/性能路由”（以开发者为先）

在一个 API Key 下支持路由到多家供应商（含美国三强与中国模型），并提供“按场景自动选模”“预算上限”“缓存命中计费透明化”。OpenRouter 研究显示开发者对新模型切换摩擦较低，且编程等高价值场景竞争激烈；因此“路由层”天然有商业空间，但其护城河来自工程与合规，而不是模型本身。⁶⁸

模式三：企业私有化/专有云交付（高客单、长周期）

面向因合规而无法使用跨境 API 的客户，提供在其指定云区域/专有环境中的部署交付、含运维与更新订阅。该模式能直接对齐“数据不出境/不出 VPC”的要求，尤其适用于希望采用开放权重但缺乏推理运维能力的中型企业。阿里云 Model Studio 在官方文档中明确提供 US 部署模式（端点与数据存储在美国），证明“以区域化数据驻留推动国际商业化”在中国厂商体系内也成立。⁶⁹

定价建议（以“可对比、可解释、可做利润”的结构为主）

定价应同时对齐两类锚点：其一是美国三强的价格上限（高能力但更贵），其二是中国模型官方 API 的价格下限（便宜但可能跨境/合规弱）。例如，代表性价格锚点包括：MiniMax-M2.5 输入/输出 \$0.30/\$1.20；Kimi kimi-k2.5 \$0.60/\$3.00（含缓存命中价）；Z.ai GLM-4.7 \$0.60/\$2.20；而 OpenAI GPT-5.4 为 \$2.50/\$15，Anthropic Opus 4.6 为 \$5/\$25，Gemini Developer API 也呈现从低价模型到高价模型的阶梯。⁷⁰

建议采用“三层定价 + 两种计费”的组合：

第一，按量计费（Pay-as-you-go）：给 Indie/小团队低门槛试用，价格可设置在“接近中国厂商官方价 + 收取合规与美国本土托管溢价”的区间，并通过缓存与批量折扣把单位成本压低。⁷¹

第二，包月/包季订阅（Developer Plan）：借鉴 MiniMax Token Plan 与 Z.ai Coding Plan 这类思路，为“编码代理/IDE 插件”提供可预测账单与并发额度。⁷²

第三，企业合约（Enterprise）：提供专有端点、SLA、合规条款（DPA、保留期、审计支持），并以“最低承诺 + 超额按量”的方式对齐企业采购习惯。可把“零/短保留、客户自持密钥、审计接口”作为差异化增值项，OpenAI 在其资料中就强调了企业可配置的数据保留与零数据保留能力。⁷³

为帮助客户快速理解差异，下面给出一个“单月成本对比”的示例框架（仅示例，实际与输入/输出比例、缓存命中率、上下文长度有关）：以 1 亿输入 tokens + 2,000 万输出 tokens 为例，使用 MiniMax-M2.5 的基础费率约为 $\$0.30 \times 100 + \$1.20 \times 20 = \$54$ ；使用 OpenAI GPT-5.4 约为 $\$2.50 \times 100 + \$15 \times 20 = \$550$ ；差异主要来自输出端价格。该计算仅用于说明“价格弹性”与“路由/缓存价值”，输入的价格锚点来自各自官方定价页。

74

合规与风险缓解措施（面向美国市场的“最小可行合规栈”）

合规目标应直接对齐美国企业采购与 DOJ 监管环境的关键关注点，而不是泛泛“我们重视隐私”：

- 数据驻留策略：默认在美国区域处理与存储客户内容与日志，向客户提供可选的区域（例如仅美国、仅欧盟）；避免把客户内容发往明确在中国存储数据的端点（DeepSeek 隐私政策披露其数据存储在**中国**）。 75
- 数据保留与训练承诺：采用“默认不训练客户输入输出 + 默认短保留 + 可选零保留”，并把实现方式透明化（哪些日志、保留多久、何种例外）。OpenAI 的 API 数据控制文档披露默认日志最长 30 天并可申请 Zero Data Retention；Google Vertex AI 也强调训练限制与零数据保留能力。 76
- DOJ 数据安全计划对齐：建立“数据分类与阈值管理”能力（识别健康、金融、精确地理位置等敏感类别与批量阈值风险），在合同与产品层面对“禁止上传的敏感数据类型/场景”作出限制，并保留客户可审计的控制与日志，以便客户证明其未开展受限交易或已采取必要缓解措施。该必要性来自 DOJ 对国家关注国家获取美国敏感数据的限制框架。 10
- 许可证与供应链治理：对 Kimi K2.5、GLM 4.5 等声明的 MIT/Modified MIT 许可进行逐项核对与归因管理（尤其是第三方 notices），并把“二次分发、托管推理、模型再训练”纳入内部合规模板。 77
- 出口管制边界意识（防未来风险）：BIS 在 AI 扩散框架中说明目前不对开放权重模型权重施加许可要求并持续监测风险；在商业计划上应预留“若未来政策变化，如何调整模型分发/下载/镜像策略”的预案。 11

市场进入步骤与优先客户群体

优先客户群体建议按“合规阻力 × 付费能力 × 成交周期”排序：

第一优先：美国 Indie 开发者与小型开发团队（工具类、编码类、内容生成类）

理由：对数据驻留要求相对弱、价格敏感、愿意尝试新模型。OpenRouter 研究显示开放权重在编程等类别的真实需求强，且新模型可快速获得采用。 78

第二优先：美国中小企业（SMB）内部效率场景（客服草稿、营销文案、内部知识库但避免敏感数据批量处理）

理由：有明确 ROI，但合规要求开始上升；需要你提供“短保留/不训练/美国驻留”的标准合同包，把供应商风险降到可接受线。 79

第三优先：受监管行业的非核心场景试点（医疗、金融、政府承包商的“低敏数据”用例）

理由：客单高但 DOJ 数据安全计划与内部采购审查更严格；只有在“美国本土部署 + 可审计合规包 + SLA”具备后才应推进。 80

执行时间线与关键里程碑

下图给出一个以“美国本土托管开放权重推理 + 合规可审计 API”为目标的 180 天执行甘特（可按团队规模压缩或拉长）。时间线内的“合规评审”需围绕 DOJ 数据安全计划与数据驻留策略展开，避免后期返工。 81


```
gantt
title 美国市场落地时间线（180天示例）
dateFormat YYYY-MM-DD
axisFormat %m-%d

section 产品与工程
API兼容层与计费系统（按量+订阅）      :a1, 2026-04-01, 45d
多模型路由/缓存/批量推理              :a2, 2026-04-15, 60d
可观测性与成本归因（tokens/延迟/失败） :a3, 2026-04-20, 60d

section 合规与法务
数据分类与保留策略设计（默认短保留/可选零保留） :b1, 2026-04-01, 30d
DPA/条款/供应链与许可证复核            :b2, 2026-04-10, 45d
DOJ数据安全计划对齐评估与缓解措施固化    :b3, 2026-04-15, 60d

section 商业化
早期开发者计划（Beta）                  :c1, 2026-05-15, 30d
付费转化与定价迭代                      :c2, 2026-06-01, 45d
企业试点（专有端点+SLA雏形）            :c3, 2026-06-15, 60d
```

关键里程碑（建议用“可验证交付物”定义）：

- M1: OpenAI 兼容 API（最小可用）上线，支持 Kimi/MiniMax/GLM 开放权重在美国区域推理，具备按量计费与用量报表。 82
- M2: 默认短保留策略与“可选零保留”落地，连同 DPA/隐私声明一并发布（对齐美国企业对数据控制的预期）。 83
- M3: 完成 DOJ 数据安全计划相关的数据映射与风险控制（数据类型限制、合同条款、客户配置项、审计留痕）。 10
- M4: 实现“成本/性能路由”与缓存计费透明化，并以 20–50 家付费开发者作为 PMF 早期验证样本。 52
- M5: 企业专有端点与 SLA（或至少状态页+支持响应承诺）上线，进入 3–5 个中型企业试点。 84

结论：明确商业建议与风险清单

商业建议（可执行、可取舍）：

- 建议一：不要把“美国市场”目标建立在“直接转售/代理中国境内部署 API”上
原因：对个人开发者虽可行，但对能带来规模收入的企业客户，数据驻留与 DOJ 数据安全计划带来的合规与采购阻力会成为主瓶颈；尤其是像 DeepSeek 这类公开声明数据存储在中国境内的服务形态，会显著压缩可触达客户范围。 85
- 建议二：以开放权重为核心，在美国本土托管推理，构建“合规版多模型 API 层”
原因：OpenRouter 数据表明中国开放权重模型在开发者侧使用增长显著；同时 B2B 支出结构（Menlo）显示企业预算倾向于购买成熟 API 与解决方案。将推理与日志驻留放在美国区域能显著提升企业可达性，且阿里云 Model Studio 已提供“US 模式端点与数据存储在美国”的先例，说明“区域化数据驻留 + 全球推理资源调度”是可商业化的工程路径。 86
- 建议三：定价上用“可解释的结构化方案”取胜，而不是单纯压价
原因：美国三强的高价位为高能力与企业合规买单；中国模型官方价更低但常伴随跨境与合规不确定。你的优

势应体现在：OpenAI 兼容、缓存命中计费透明、可预测订阅、美国驻留与可审计合规包。价格可保持“显著低于美国三强旗舰、略高于中国官方跨境价”的合理溢价，以覆盖美国本土部署与合规成本。⁸⁷

风险清单（建议在立项阶段就建立“风险—触发条件—缓解措施—责任人”台账）：

- 监管与地缘政治风险：DOJ 数据安全计划对与国家关注国家相关的数据交易施加限制/禁止，可能导致客户合规审查失败或合同条款大幅收紧；政策演进也可能改变“允许处理的数据类型与阈值”。¹⁰
- 数据驻留与隐私风险：若供应商隐私政策明确数据在中国境内存储，将显著限制美国企业客户可达性；即使在新加坡等地，也可能不满足“美国本土驻留”要求。⁸⁸
- 许可证与知识产权风险：开放权重虽常用 MIT/Apache 等宽松许可，但不同版本与组件差异可能导致误用；需要建立持续的许可证治理与归因流程。⁸⁹
- 网络与可用性风险：跨境链路波动与审查机制会抬高延迟与失败率，尤其影响代理式多轮调用；因此若要卖企业服务，必须把推理落地在美国或客户指定区域并提供 SLA。⁹⁰
- 商业化风险：企业端市场份额高度集中在美国三强（Menlo 估算 2025 年合计约 88%），若缺乏“合规+部署+集成”差异化，仅靠价格难以撼动企业预算。⁴

综合判断：若目标是在美国实现可持续规模收入，应把“Minimax/Kimi/GLM 的优势”定位为“开放权重带来的可部署性与成本效率”，而把产品竞争重心放在“美国本土托管、合规可审计、可路由多模型、可预测成本与 SLA”上；并以开发者与小团队切入，逐步向更高合规行业拓展。⁹¹

¹ ⁵ ¹⁰ ¹⁸ ³³ ⁸⁰ ⁸¹ ⁸⁵ <https://www.justice.gov/nsd/data-security>

<https://www.justice.gov/nsd/data-security>

² ⁶ ⁷ ⁸ ⁹ ¹⁵ ¹⁷ ²⁴ ²⁹ ⁴⁹ ⁵² ⁵³ ⁵⁴ ⁶⁰ ⁶⁷ ⁶⁸ ⁷⁸ ⁸⁶ ⁹¹ <https://openrouter.ai/state-of-ai>

<https://openrouter.ai/state-of-ai>

³ ¹³ 2025 Stack Overflow Developer Survey

https://survey.stackoverflow.co/2025/?utm_source=chatgpt.com

⁴ ⁵⁶ ⁸⁴ <https://menlovc.com/perspective/2025-the-state-of-generative-ai-in-the-enterprise/>

<https://menlovc.com/perspective/2025-the-state-of-generative-ai-in-the-enterprise/>

¹¹ <https://www.federalregister.gov/documents/2025/01/15/2025-00636/framework-for-artificial-intelligence-diffusion>

<https://www.federalregister.gov/documents/2025/01/15/2025-00636/framework-for-artificial-intelligence-diffusion>

¹² ⁴² ⁴⁵ ⁷⁷ ⁸⁹ <https://huggingface.co/moonshotai/Kimi-K2.5>

<https://huggingface.co/moonshotai/Kimi-K2.5>

¹⁴ <https://a16z.com/state-of-consumer-ai-2025-product-hits-misses-and-whats-next/>

<https://a16z.com/state-of-consumer-ai-2025-product-hits-misses-and-whats-next/>

¹⁶ ²⁶ ⁴⁰ <https://platform.moonshot.ai/docs/pricing/faq>

<https://platform.moonshot.ai/docs/pricing/faq>

¹⁹ ²⁸ ⁶² <https://platform.moonshot.ai/docs/agreement/userprivacy>

<https://platform.moonshot.ai/docs/agreement/userprivacy>

²⁰ ²¹ ⁷⁰ ⁷⁴ <https://platform.minimax.io/docs/guides/pricing-paygo>

<https://platform.minimax.io/docs/guides/pricing-paygo>

²² ⁷² Token Plan - Models - MiniMax API Docs

https://platform.minimax.io/docs/guides/pricing-token-plan?utm_source=chatgpt.com

23 <https://platform.minimax.io/protocol/privacy-policy>
<https://platform.minimax.io/protocol/privacy-policy>

25 37 71 82 <https://platform.moonshot.ai/>
<https://platform.moonshot.ai/>

27 30 58 <https://docs.z.ai/guides/overview/pricing>
<https://docs.z.ai/guides/overview/pricing>

31 <https://z.ai/subscribe>
<https://z.ai/subscribe>

32 <https://docs.z.ai/legal-agreement/privacy-policy>
<https://docs.z.ai/legal-agreement/privacy-policy>

34 [pricing-details-usd | DeepSeek API Docs](#)
https://api-docs.deepseek.com/quick_start/pricing-details-usd?utm_source=chatgpt.com

35 57 <https://api-docs.deepseek.com/faq>
<https://api-docs.deepseek.com/faq>

36 63 66 75 88 <https://cdn.deepseek.com/policies/en-US/deepseek-privacy-policy-2025-02-14.html>
<https://cdn.deepseek.com/policies/en-US/deepseek-privacy-policy-2025-02-14.html>

38 69 <https://www.alibabacloud.com/help/en/model-studio/models>
<https://www.alibabacloud.com/help/en/model-studio/models>

39 <https://www.alibabacloud.com/help/en/model-studio/model-pricing>
<https://www.alibabacloud.com/help/en/model-studio/model-pricing>

41 <https://github.com/QwenLM/Qwen/blob/main/LICENSE>
<https://github.com/QwenLM/Qwen/blob/main/LICENSE>

43 87 <https://openai.com/api/pricing/>
<https://openai.com/api/pricing/>

44 79 <https://openai.com/enterprise-privacy/>
<https://openai.com/enterprise-privacy/>

46 <https://platform.claude.com/docs/en/about-claude/pricing>
<https://platform.claude.com/docs/en/about-claude/pricing>

47 48 <https://www.anthropic.com/news/claude-opus-4-6>
<https://www.anthropic.com/news/claude-opus-4-6>

50 <https://ai.google.dev/gemini-api/docs/pricing>
<https://ai.google.dev/gemini-api/docs/pricing>

51 65 <https://docs.cloud.google.com/vertex-ai/generative-ai/docs/vertex-ai-zero-data-retention>
<https://docs.cloud.google.com/vertex-ai/generative-ai/docs/vertex-ai-zero-data-retention>

55 [ChatGPT reaches 900M weekly active users](#)
https://techcrunch.com/2026/02/27/chatgpt-reaches-900m-weekly-active-users/?utm_source=chatgpt.com

59 90 <https://gfw.report/publications/usenixsecurity25/en/>
<https://gfw.report/publications/usenixsecurity25/en/>

⁶¹ <https://www.federalregister.gov/documents/2024/03/01/2024-04573/preventing-access-to-americans-bulk-sensitive-personal-data-and-united-states-government-related>
<https://www.federalregister.gov/documents/2024/03/01/2024-04573/preventing-access-to-americans-bulk-sensitive-personal-data-and-united-states-government-related>

⁶⁴ https://en.npc.gov.cn.cdurl.cn/2021-12/29/c_694559.htm
https://en.npc.gov.cn.cdurl.cn/2021-12/29/c_694559.htm

⁷³ <https://openai.com/business-data/>
<https://openai.com/business-data/>

⁷⁶ ⁸³ <https://developers.openai.com/api/docs/guides/your-data/>
<https://developers.openai.com/api/docs/guides/your-data/>